

# Predict Bitcoin by VRG



# Punctul de plecare în dezvoltarea acestei aplicații

Analiza, modelarea și predicția prețului Bitcoin utilizând modele ARIMA și simulații Monte Carlo

- **Modelele ARIMA în analiza seriilor temporale:** surprinde dinamica dependențelor temporale în procese precum prețurile financiare.
- **Obiectivul prognozei monedei BTC:** Prognoza prețului Bitcoin pe baza datelor istorice și log-returnurilor asociate.
- **Simulații Monte Carlo:** Este o metodă prin care se generează scenarii multiple în evoluția prețului, evidențiind incertitudinea.

**Log-Return** = măsoară schimbarea procentuală a prețului dintre două momente, folosind logaritmul natural



Photo by André François McKenzie on Unsplash

$$\text{Log-return}_t = \ln \left( \frac{P_t}{P_{t-1}} \right)$$

unde:

- $P_t$ : prețul la momentul  $t$ ,
- $P_{t-1}$ : prețul la momentul anterior ( $t - 1$ ),
- $\ln$ : logaritmul natural (bază  $e$ ).

# De ce Modelul ARIMA?

Prezentare Generală a motivului pentru care Arima > Rețea Neuronală în cazul de față

- **Definiție SIMPLA:** ARIMA este folosit pentru analiza **serilor temporale** și a prognoza **valori viitoare**.
- **Componentele ARIMA:** AutoRegresiv (AR), Integrare (I) și Medie Alunecătoare (MA)  
[ Le vom aborda pagina urmatoare ].
- **Aplicații în predicția financiară:** Model aplicat la nivel mondial pentru analiza de prețuri, rate de schimb și randamente financiare pe poziții medii sau scurte.



Photo by Mari Helin on Unsplash

# Componentele Modelului ARIMA

**DICȚIONAR PENTRU:** AutoRegresiv, Integrare și Medie Mobilă



## AutoRegresiv (AR)

Valoarea curentă este influențată de valorile trecute ponderate de coeficienții AR.

$$X_t = \phi_0 + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \cdots + \phi_p X_{t-p} + \varepsilon_t,$$

unde:

- $X_t$ : valoarea curentă a seriei temporale,
- $\phi_0$ : interceptul modelului (constanta),
- $\phi_i$ : coeficienți autoregresivi (determină cât de mult influențează  $X_{t-i}$ ),
- $p$ : numărul de termeni autoregresivi,
- $\varepsilon_t$ : eroarea (zgomot alb) la momentul  $t$ .



## Integrare (I)

Se aplică diferențieri pentru a face seria staționară.

$$X'_t = \nabla^d X_t = X_t - X_{t-1},$$

unde:

- $d$ : numărul de diferențieri necesare pentru a face seria staționară,
- $\nabla$ : operatorul de diferențiere.

Exemplu pentru  $d = 1$ :

$$X'_t = X_t - X_{t-1}.$$



## Media Alunecatoare (MA)

Valoarea curentă este afectată de erorile din perioade anterioare.

$$X_t = \theta_0 + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \cdots + \theta_q \varepsilon_{t-q},$$

unde:

- $\varepsilon_t$ : eroarea curentă (diferența dintre valoarea reală și cea prezisă),
- $\theta_0$ : interceptul modelului,
- $\theta_i$ : coeficienți ai mediei mobile,
- $q$ : numărul de termeni ai erorilor trecute.

# Formule și Modelul ARIMA(1,0,1)

Formulele/expresiile matematice ale componentelor modelului



## Formula generală ARIMA

$$\Phi(B)(1-B)^d X_t = \Theta(B) \varepsilon_t,$$



## Modelul ARIMA(1,0,1)

$$X_t = c + \phi_1 X_{t-1} + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$



## Reziduuri și zgomot alb

$$\varepsilon_t = X_t - \hat{X}_t$$

unde  $\hat{X}_t$  este valoarea prezisă de model.

unde:

- $B$  este **operatorul de întârziere** (lag operator), cu proprietatea  $B(X_t) = X_{t-1}$ .
- $(1 - B)^d$  reprezintă **diferențierea** de ordin  $d$ .
- $\Phi(B)$  este polinomul autoregresiv:

$$\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p.$$

- $\Theta(B)$  este polinomul de medie mobilă:

$$\Theta(B) = 1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q.$$

- $\varepsilon_t$  este **termenul de eroare** (zgomot alb), adică reziduul la momentul  $t$ .

Atunci când  $p=1$ ,  $d=0$  și  $q=1$ , avem:

AR(1): valoarea curentă a seriei depinde de valoarea de la pasul anterior,

Nu există diferențiere ( $d=0$ ),

MA(1): valoarea curentă depinde de eroarea (reziduul) anterioară.

- $c$  (uneori notat  $\phi_0$ ) este **constantă** (termenul liber),
- $\phi_1$  este **coeficientul autoregresiv**,
- $\theta_1$  este **coeficientul de medie mobilă**,
- $\varepsilon_t$  este **termenul de eroare** (reziduul) la momentul  $t$ , cu medie 0 și varianță constantă  $\sigma^2$

Rezidurile sunt necesare pentru simulare și prognoză, el stabilește Calitatea modelului, Estimarea incertitudinii și Diagnosticare prin grafic.

(mai multe informații la pg. 10)

# Explicația Mecanicii Codului

## Preprocesarea Datelor

- **Importul datelor din fișier Excel:** Se încarcă prețurile zilnice BTC și se pregătesc pentru analiză.
- **Transformarea datelor:** Din prețurile BTC citite, se calculează mai întâi logaritmul natural al prețului. Apoi, din acesta se determină log-return, adică diferența dintre log-price de astăzi și cel de ieri. Astfel, obținem o serie mai stabilă (staționare), ceea ce face analizele statistice (precum modelele ARIMA) mai sigure/fiabile.
- **Prelucrarea indexului temporal:** Datele sunt convertite în format de tip **datetime**, ceea ce permite sortarea cronologică. Apoi, acestea sunt setate ca index (de exemplu, coloana **Date** devine index), facilitând ordonarea corectă a observațiilor și posibilitatea de a selecta perioade de timp specifice mai ușor de către script.

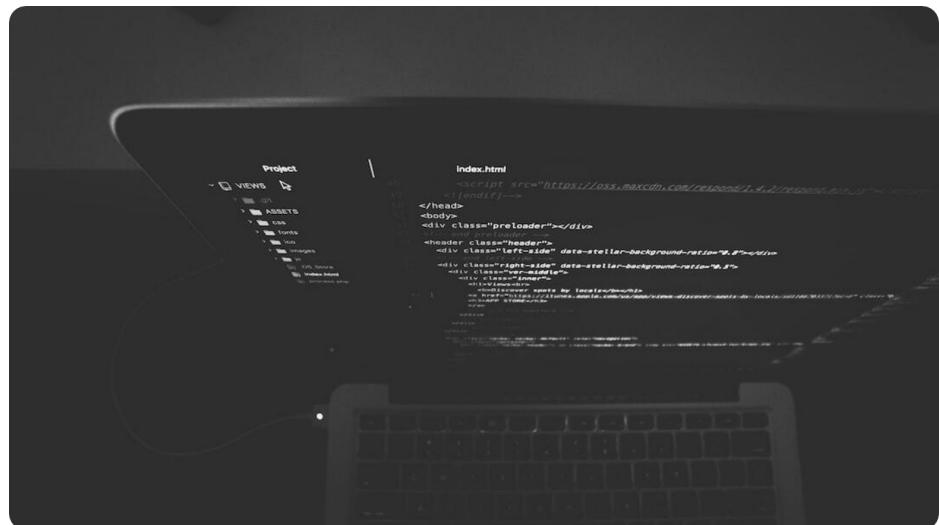


Photo by Nate Grant on Unsplash

# Explicația Mecanicii Codului

## Antrenarea Modelului ARIMA



**Definirea parametrilor ARIMA**  
Se setează valorile p, d și q (1, 0, 1) pentru model.



**Utilizarea librăriei Statsmodels**  
Modelul ARIMA este antrenat pe baza seriei de log-return.



**Estimarea coeficientilor**  
Parametrii modelului ( $\phi$ ,  $\theta$ ,  $\sigma$ ) sunt extrași și analizați.



# Simulare Monte Carlo

## Metodologie



### Definiția metodei Monte Carlo

Eșantionarea repetată dintr-o distribuție pentru estimarea unui proces probabilistic.



### Aplicarea în prognoza BTC

Generarea de traiectorii posibile ale prețului folosind randamente simulate.



### Beneficii

Oferă scenarii probabilistice și evidențiază incertitudinea prognozelor.

Metoda Monte Carlo aproximează  $\mathbb{E}[f(X)]$  (sau alte mărimi statistice) prin eșantionarea repetată a lui  $X$  dintr-o distribuție probabilistică și calcularea mediei funcției  $f$  asupra acestor eșantioane, oferind astfel o estimare numerică a comportamentului procesului aleator.

# Simulare Monte Carlo

## Fluxul și Interpretarea

- **Fluxul simulării:** Pleacă de la un preț inițial și iterează zilnic prin randamentele simulate.
  - **Generarea traiectoriilor:** Aceste randamente simulate includ șocuri bazate pe reziduurile istorice.
  - **Rezultate și interpretare:** Se calculează percentila 25%-75% și mediană pentru a obține o bandă de încredere.
- 
- **Percentila 25% (Q1):** valoarea sub care cad 25% din simulări
  - **Percentila 75% (Q3):** valoarea peste care cad 25% din simulări

Astfel, intervalul [25%, 75%] acoperă 50% din scenariile centrale. **Mediana** este valoarea de mijloc, sub care și peste care sunt 50% din simulări.



Photo by Terry Vlisidis on Unsplash

# Rolul Reziduurilor în Model

Importanță și utilizare în ARIMA



## Definiție

Reziduurile sunt diferențele între valori observate și cele estimate.



## Verificarea modelului

Calitatea modelului este evaluată prin analiza reziduurilor. Prin analizarea distribuției și autocorelației reziduurilor, putem valida dacă modelul este adecvat.



## Utilizare în simulare

Reziduurile contribuie la generarea řocurilor în simularea Monte Carlo explicata la pagina 9.

# Concluzii și Observații Finală

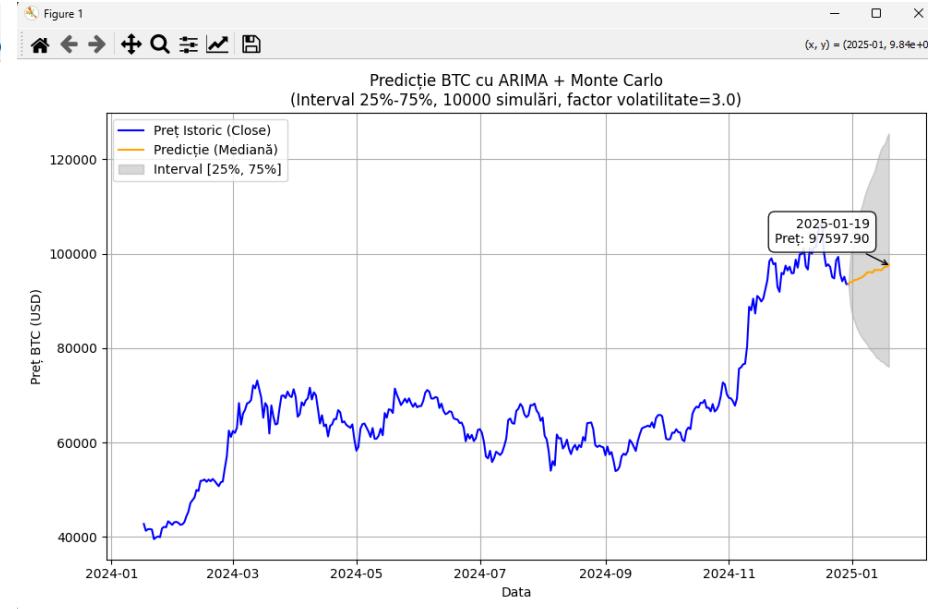
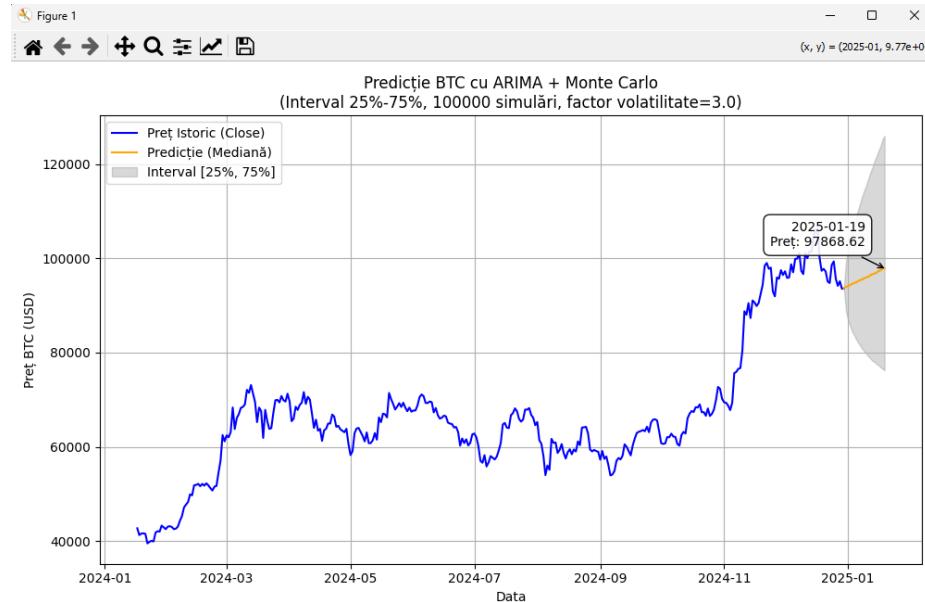
## Învățăminte și aplicații practice

- **Valoarea modelelor ARIMA:** Instrumente robuste pentru prognoza seriilor temporale financiare.
  - **Simularea Monte Carlo:** Abordare probabilistică pentru a înțelege volatilitatea și riscul.
  - **Limitări și recomandări:** Modelele necesită interpretare critică și includerea altor informații relevante.
- MY\_VRG\_CODE:

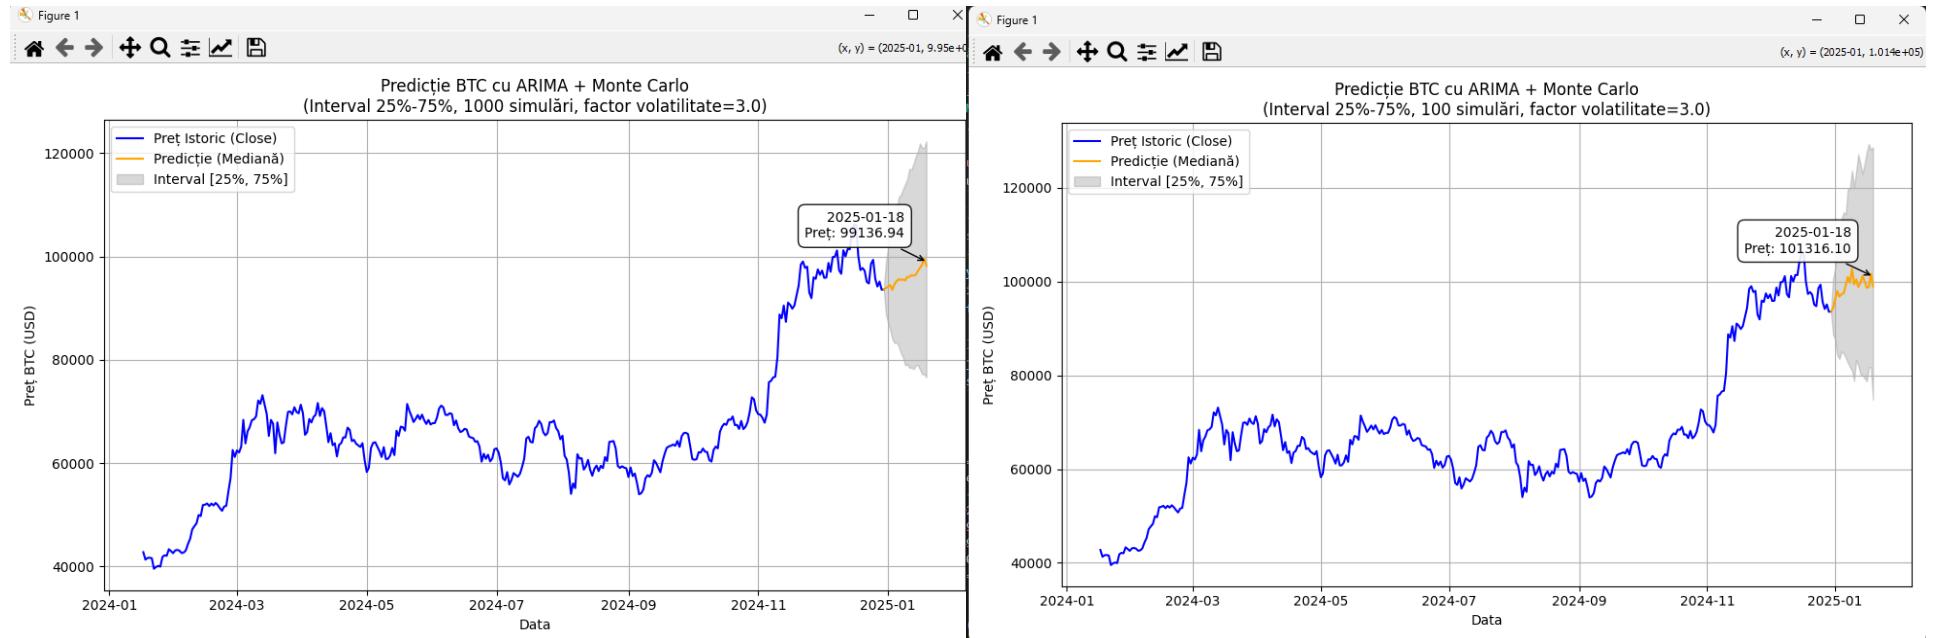


Photo by Mari Helin on Unsplash

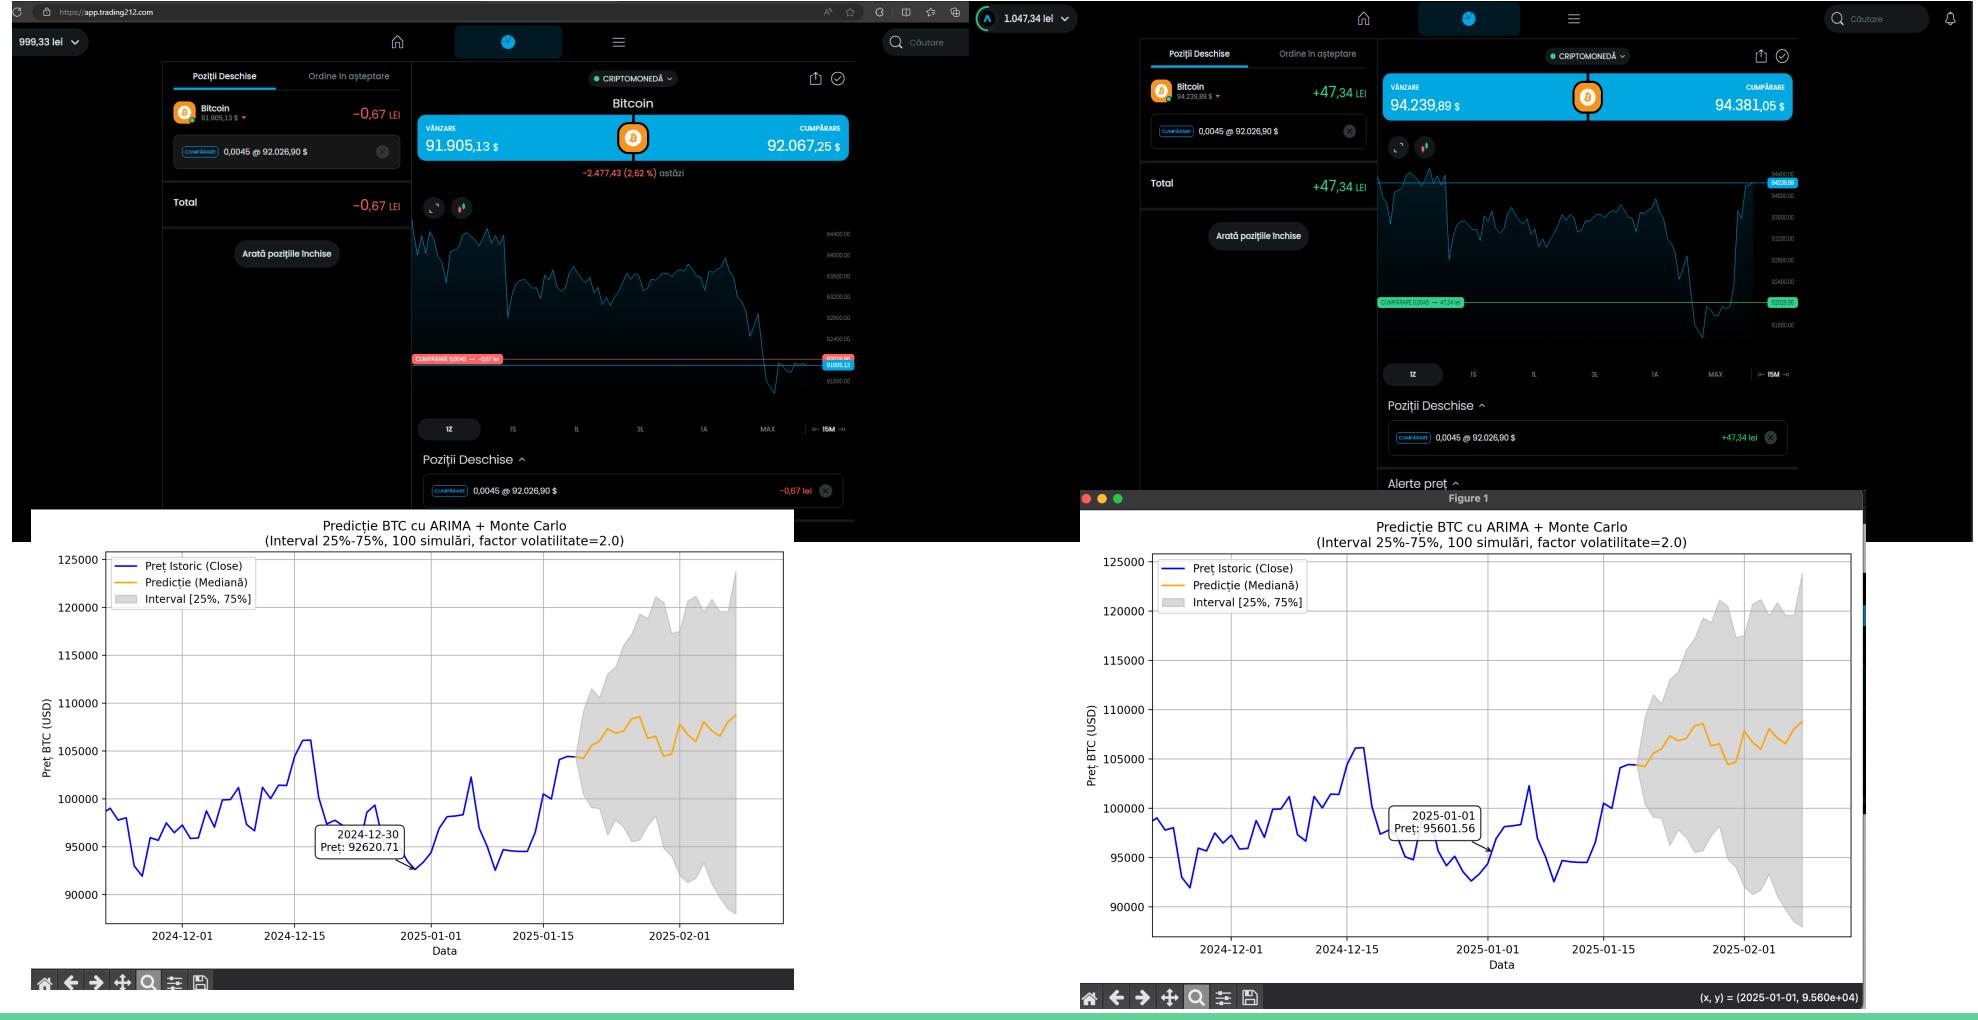
# Concluzii



# Concluzii



# Concluzii



# Concluzii

Python

ProjectBITCOIN

EXPLORER

OPEN EDITORS

PROJECTBITCOIN

BitcoinSimulare

bitcoin\_daily\_price\_history.... M

graphextract.py M

LICENSE

predictie.py M

Captura\_de\_ecran\_202

Captura\_de\_ecran\_202

Captura\_de\_ecran\_202

Captura\_de\_ecran\_202

Captura\_de\_ecran\_202

Captura\_de\_ecran\_202

IMG\_8546.PNG

graphextract.py M predictie.py M

BitcoinSimulare > predictie.py > ...

```
33 # ...
34 # 3) Antrenăm un model ARIMA pe log_return
35 #
36 p, d, q = 1, 0, 1
37 model = ARIMA(df['log_return'], order=(p, d, q))
38 fit = model.fit()
```

Figure 1

Predictie BTC cu ARIMA + Monte Carlo  
(Interval 25%-75%, 100 simulări, factor volatilitate=2.0)

Pret BTC (USD)

Preț Istoric (Close)

Predictie (Mediană)

Interval [25%, 75%]

2024-11-15 2024-12-01 2024-12-15 2025-01-01 2025-01-15 2025-02-01 2025-02-15

Data

2025-01-09  
Preț: 92659.21

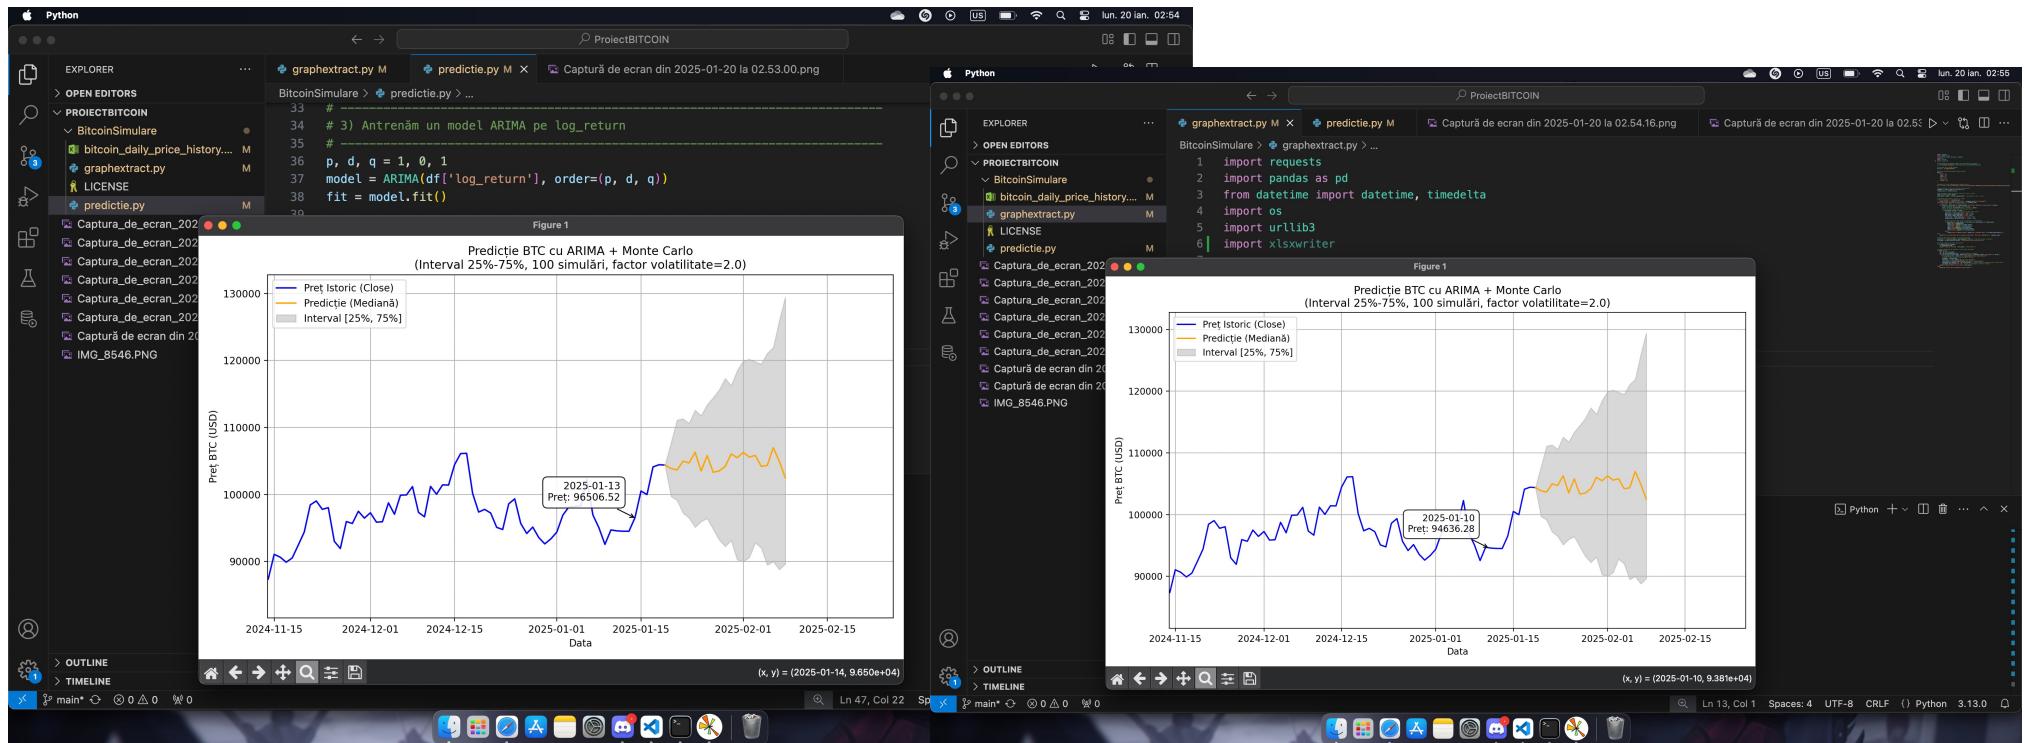
(x, y) = (2025-01-09, 9.265e+04)

Python

Ln 47, Col 22 Spaces: 4 UTF-8 CRLF Python 3.13.0

The screenshot shows a Python development environment with a dark theme. In the top right, there's a status bar with the date 'lun. 20 ian. 02:53'. The main area has two open files: 'graphextract.py' and 'predictie.py'. The 'predictie.py' file contains code for training an ARIMA model on Bitcoin daily price history. A figure window titled 'Figure 1' displays a line graph of Bitcoin price from November 2024 to February 2025. The graph includes historical data (blue line), a median prediction (orange line), and a 25%-75% confidence interval (shaded gray area). A callout box highlights a specific prediction point for January 9, 2025, at a price of 92,659.21 USD. The bottom status bar shows the current line and column numbers (Ln 47, Col 22), and the Python version (3.13.0).

# Concluzii



# Concluzii

